

华中科技大学

HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY


计算机视觉导论

任课教师：李贤芝

计算机科学与技术学院


数字图像处理基础

- 图像采样与量化
- 图像滤波与卷积
- 图像放缩





计算机中的数字图像

- 数字图像是由有限数量的元素组成的，每个元素都有一个特定的位置和幅值，这些元素称为**像素**。可以定义一个二维函数 $f(x, y)$ ，其中 (x, y) 是空间坐标， $f(x, y)$ 是点 (x, y) 的幅值。
 - 在灰度图像中，每个像素只用一个值表示。
 - 在彩色图像中，每个像素用多个值表示。



灰度图像

- 每个像素只有一个采样颜色的图像。通常有256个灰度等级，255代表全白，0代表全黑。



灰度
图像


VS.



黑白
图像


彩色图像的常用颜色模型

- 在彩色图像中，每个像素用多个值表示。




RGB颜色模型

- 最典型、最常用的三基色模型
- 电视、摄像机、彩色扫描仪都是根据RGB模型工作的
- 不直观，不符合人对颜色的认知



HSV颜色模型

- H: 色调; S: 饱和度; V: 亮度值
- 与人类对颜色的感知更接近




CMYK颜色模型

- 主要用于彩色打印，图像处理中几乎不用

彩色图像的常用颜色模型


- 在彩色图像中，每个像素用多个值表示。



RGB颜色模型



RGB 图像



B 分量



G 分量




R 分量

计算机中的数字图像

- 数字图像是由有限数量的元素组成的，每个元素都有一个特定的位置和幅值，这些元素称为**像素**。可以定义一个二维函数 $f(x, y)$ ，其中 (x, y) 是空间坐标， $f(x, y)$ 是点 (x, y) 的幅值。

- 在灰度图像中，每个像素只用一个值表示。
- 在彩色图像中，每个像素用多个值表示。




- 传感器获取的图像是平面上的**连续函数**。为了产生一副数字图像，需要把连续的感知数据转换为数字形式，这包括**采样 (Sampling)** 和**量化 (Quantization)**两个基本步骤。

图像的采样

- 图像采样：图像空间坐标的数字化 [可以理解为坐标点的选取]


如果对同一幅图像采样间隔越小：

- 所得像素越多，图像的空间分辨率越高，细节越清晰
- 文件尺寸大，处理时间长，对设备要求高



图像的量化


- 图像量化：图像函数值 (灰度值) 的数字化 [可以理解为幅值的数字化]
 - 均匀量化：将灰度级值等间隔分档取整
 - 随着灰度等级的减少，图像的细节信息在逐渐损失，视觉效果越差。



256个层次的图像

64个层次的图像

16个层次的图像



图像的采样与量化

- 不同采样点数对图像质量的影响:





(a): 512×512 (b): 256×256 (c): 128×128
(d): 64×64 (e): 32×32 (f): 16×16

- 不同量化级别对图像质量的影响:




(a): 256 (b): 64 (c): 16
(d): 8 (e): 4 (f): 2

图像滤波与卷积



平滑/锐化图像



边缘检测




模板匹配



图像滤波与卷积的动机 – 降噪

- 在图像产生、传输和复制过程中，常常会因为多方面原因而被噪声干扰，降低了图像质量，这就需要对图像进行一定的处理以减小这些缺陷带来的影响。
- 噪声在图像上常表现为引起较强视觉效果的孤立像素点或者像素块。
- 对于数字图像，噪声表现为或大或小的极值，这些极值通过加减作用于图像像素的真实灰度值上，对图像造成亮、暗点干扰，降低了图像的视觉质量，影响图像复原、分割、特征提取、图像识别等后继工作的进行。




噪声类型

椒盐噪声：黑白像素的随机出现。

脉冲噪声：白色像素的随机出现。

高斯噪声：服从高斯分布的噪声。



Original



Salt and pepper noise




Impulse noise






Gaussian noise

高斯分布：也叫正态分布（normal distribution），通常记作 $X \sim N(\mu, \sigma^2)$ 。其中， μ 是正态分布的均值， σ^2 是正态分布的方差。 $\mu = 0, \sigma^2 = 1$ 的正态分布被称作标准正态分布。

正态分布的概率密度函数显示为典型的钟形曲线。 μ 描述了分布的中心位置，即曲线对称轴所在位置； σ^2 描述了随机变量相对于均值的偏离程度。




高斯噪声



$$f(x, y) = \overbrace{\hat{f}(x, y)}^{\text{Ideal Image}} + \overbrace{\eta(x, y)}^{\text{Noise process}}$$


Gaussian i.i.d. ("white") noise:
 $\eta(x, y) \sim \mathcal{N}(\mu, \sigma)$

高斯噪声图



$$\sigma = 1$$

VS.



$$\sigma = 16$$

高斯噪声加到原始图像上



$$\sigma = 1$$


VS.



$$\sigma = 16$$

均值滤波

- 用每个像素和它周围像素计算出来的平均值替换图像中的每个像素。
- 消除尖锐噪声，实现图像平滑、模糊等功能。



取周围五个位置的像素，
五个像素的权重为 $[1, 1, 1, 1, 1] / 5$

二维：像素值相加后求平均

$F[x, y]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$G[x, y]$

	0								

$$F[x, y]$$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$$G[x, y]$$

	0	10							

$$F[x, y]$$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$$G[x, y]$$

	0	10	20						

$$F[x, y]$$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$$G[x, y]$$

	0	10	20	30					

$$F[x, y]$$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$$G[x, y]$$

	0	10	20	30	30				


$$F[x, y]$$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0


$$G[x, y]$$

	0	10	20	30	30	30	20	10	
	0	20	40	60	60	60	40	20	
	0	30	60	90	90	90	60	30	
	0	30	50	80	80	90	60	30	
	0	30	50	80	80	90	60	30	
	0	20	30	50	50	60	40	20	
	10	20	30	30	30	30	20	10	
	10	10	10	0	0	0	0	0	


原图像



3X3均值滤波器




5X5均值滤波器





随着窗口的增大，图像越来越模糊！

中值滤波


- 用每个像素和它周围像素的中值替换图像中的每个像素。
- 对脉冲噪声和椒盐噪声有良好的效果。




加了椒盐噪声的图像



中值滤波后的图像



中值滤波可以有效保留边缘



高斯滤波

- 用每个像素和它周围像素的加权平均灰度值替换图像中的每个像素。距离中心像素越近，分配权重越大。
- 适用于消除高斯噪声。

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0


$F[x, y]$

1	2	1
2	4	2
1	2	1

$H[u, v]$


高斯滤波核是对高斯方法的模拟近似。

$$h(u, v) = \frac{1}{2\pi\sigma^2} e^{-\frac{u^2+v^2}{\sigma^2}}$$




高斯滤波的参数

- 高斯滤波核的大小：
 σ 固定，核越大图像越模糊。




$\sigma = 5$
 10×10




$\sigma = 5$
 30×30



- 标准差 σ 的大小：
核固定， σ 越大图像越模糊。





$\sigma = 2$
 30×30



$\sigma = 25$
 30×30





$\sigma = 1$
30 x 30



$\sigma = 4$
30 x 30

...



$\sigma = 10$
30 x 30

卷积

- 互相关：对图像矩阵和滤波矩阵按位进行逐个元素相乘再求和的操作。
- 卷积：先对滤波矩阵顺时针旋转180° (由下到上，由右到左)，而后再按位点乘求和。

$$G[i, j] = \sum_{u=-k}^k \sum_{v=-k}^k H[u, v] F[i - u, j - v]$$

↑
卷积核

注：深度学习中的卷积可以看作互相关运算，因为深度学习中的卷积核的参数是可学习的，无所谓翻转与否。

卷积

- 互相关：对图像矩阵和滤波矩阵按位进行逐个元素相乘再求和的操作。
- 卷积：先对滤波矩阵顺时针旋转180° (由下到上，由右到左)，而后再按位点乘求和。

$F[x, y]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

*

卷积核

1/9	1/9	1/9
1/9	1/9	1/9
1/9	1/9	1/9

$H[u, v]$

=

$G[x, y]$


	0	10	20	30	30	30	20	10	
	0	20	40	60	60	60	40	20	
	0	30	60	90	90	90	60	30	
	0	30	50	80	80	90	60	30	
	0	30	50	80	80	90	60	30	
	0	20	30	50	50	60	40	20	
	10	20	30	30	30	30	20	10	
	10	10	10	0	0	0	0	0	

图像滤波与卷积的动机 – 提取特征

- 一开始，是将滤波看作一种去除噪声的方式。
- 现在，考虑滤波器如何提取高层特征。
 - 将原始像素映射到某种表示，以便后续处理；
 - 减少数据量，丢弃冗余，保留有用的内容（如边缘信息）。

图像边缘检测

- 边缘是像素值发生突变的地方，也是图像中信息最集中的地方。图像边缘通常由多种因素引起：



如何判断一个像素是否属于边？

图像梯度

导数：

对于函数 $f(x)$ ，它的一阶导数记为 $f'(x)$ ，二阶导数记为 $f''(x)$

$$f'(x) = \frac{df(x)}{dx} = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$

$$f''(x) = \frac{df'(x)}{dx} = \lim_{\Delta x \rightarrow 0} \frac{f'(x + \Delta x) - f'(x)}{\Delta x}$$

$f'(x)$ 表示 $f(x)$ 沿 x 方向的变化速率

$f''(x)$ 表示 $f'(x)$ 沿 x 方向的变化速率

图像梯度

偏导数：

对于二元函数 $f(x, y)$ ，对变量 x 的偏导数记为 $f'_x(x, y)$ ，对变量 y 的偏导数记为 $f'_y(x, y)$

$$f'_x(x, y) = \frac{\partial f(x, y)}{\partial x} = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y) - f(x, y)}{\Delta x}$$
$$f'_y(x, y) = \frac{\partial f(x, y)}{\partial y} = \lim_{\Delta y \rightarrow 0} \frac{f(x, y + \Delta y) - f(x, y)}{\Delta y}$$

梯度：

对于二元函数 $f(x, y)$ ，梯度 $gradient = \nabla f(x, y) = [f'_x(x, y), f'_y(x, y)]$


梯度是一个向量，表示函数 $f(x, y)$ 在点 (x, y) 处沿着该方向（梯度方向）变化最快，变化率最大（梯度的模）

图像梯度


$$\nabla f = \left[\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right]$$

梯度指向强度最快速变化的方向，图像梯度计算的是图像像素值变化的速度：


- 对于图像的边缘部分，因为其灰度值变化较大，所以梯度值也较大
- 对于图像中比较平滑的部分，因为其灰度值变化较小，所以梯度值也较小



水平方向强度变化最快



垂直方向强度变化最快



45°方向强度变化最快


如何对一个数字图像求梯度？

离散梯度

- 有限差分:

$$\frac{\partial f}{\partial x}[x, y] \approx F[x + 1, y] - F[x - 1, y]$$

$$\frac{\partial f}{\partial y}[x, y] \approx F[x, y + 1] - F[x, y - 1]$$



离散梯度

- 例：计算水平方向的差分

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

 $*$

-1	0	1
-1	0	1
-1	0	1

 $=$

-270

0

离散梯度

- 例：计算垂直方向的差分

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

 $*$

1	1	1
0	0	0
-1	-1	-1

 $=$

-270
0

离散梯度

- 有限差分：

$$\frac{\partial f}{\partial x}[x, y] \approx F[x + 1, y] - F[x - 1, y]$$

$$\frac{\partial f}{\partial y}[x, y] \approx F[x, y + 1] - F[x, y - 1]$$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

*

-1	0	1
-1	0	1
-1	0	1

or

1	1	1
0	0	0
-1	-1	-1

水平差分

垂直差分

边缘检测本质上就是一种滤波，区别在于滤波器的选择，滤波的规则是完全一样的！

对不同方向进行求导的滤波器

Prewitt: $M_x =$

-1	0	1
-1	0	1
-1	0	1

 ; $M_y =$

1	1	1
0	0	0
-1	-1	-1

Sobel: $M_x =$

-1	0	1
-2	0	2
-1	0	1

 ; $M_y =$

1	2	1
0	0	0
-1	-2	-1

Roberts: $M_x =$

0	1
-1	0

 ; $M_y =$

1	0
0	-1

Sobel算子比Prewitt算子边缘检测性能更好，
Roberts算子计算对角线上而不是相邻两个像素的差分。

图像边缘检测


- 寻找45°边缘:



*

-1	0	0	0	0
0	-2	0	0	0
0	0	6	0	0
0	0	0	-2	0
0	0	0	0	-1

=




- 寻找所有方向的边缘:



*

-1	-1	-1
-1	8	-1
-1	-1	-1

=



Canny边缘检测器

1. 图像降噪
2. 计算图像梯度
3. 非极大值抑制
 - 将多像素宽的边缘减少至一个像素宽度。
 - 规则：对每个“边缘”像素，沿着它的梯度方向，跟邻域像素的梯度强度进行比较，如果是局部极大值，则视为边缘像素，否则丢弃。
4. 双阈值筛选
 - 使用上下两个阈值来筛选。
 - 大于上阈值的认为是边缘点，小于下阈值的认为是非边缘点，在两个阈值之间的，如果与确定为边缘的点相邻接，认为是边缘点，否则剔除掉。




(a) Original




(b) Smoothed



(b) Gradient magnitudes




(b) Edges after non-maximum suppression




(b) Double thresholding



Canny边缘检测器

1. 图像降噪
2. 计算图像梯度
3. 非极大值抑制
 - 将多像素宽的边缘减少至一个像素宽度。
 - 规则：对每个“边缘”像素，沿着它的梯度方向，跟邻域像素的梯度强度进行比较，如果是局部极大值，则视为边缘像素，否则丢弃。
4. 双阈值筛选
 - 使用上下两个阈值来筛选。
 - 大于上阈值的认为是边缘点，小于下阈值的认为是非边缘点，在两个阈值之间的，如果与确定为边缘的点相邻接，认为是边缘点，否则剔除掉。




边缘检测前为什么要降噪？






高斯函数



高斯平滑

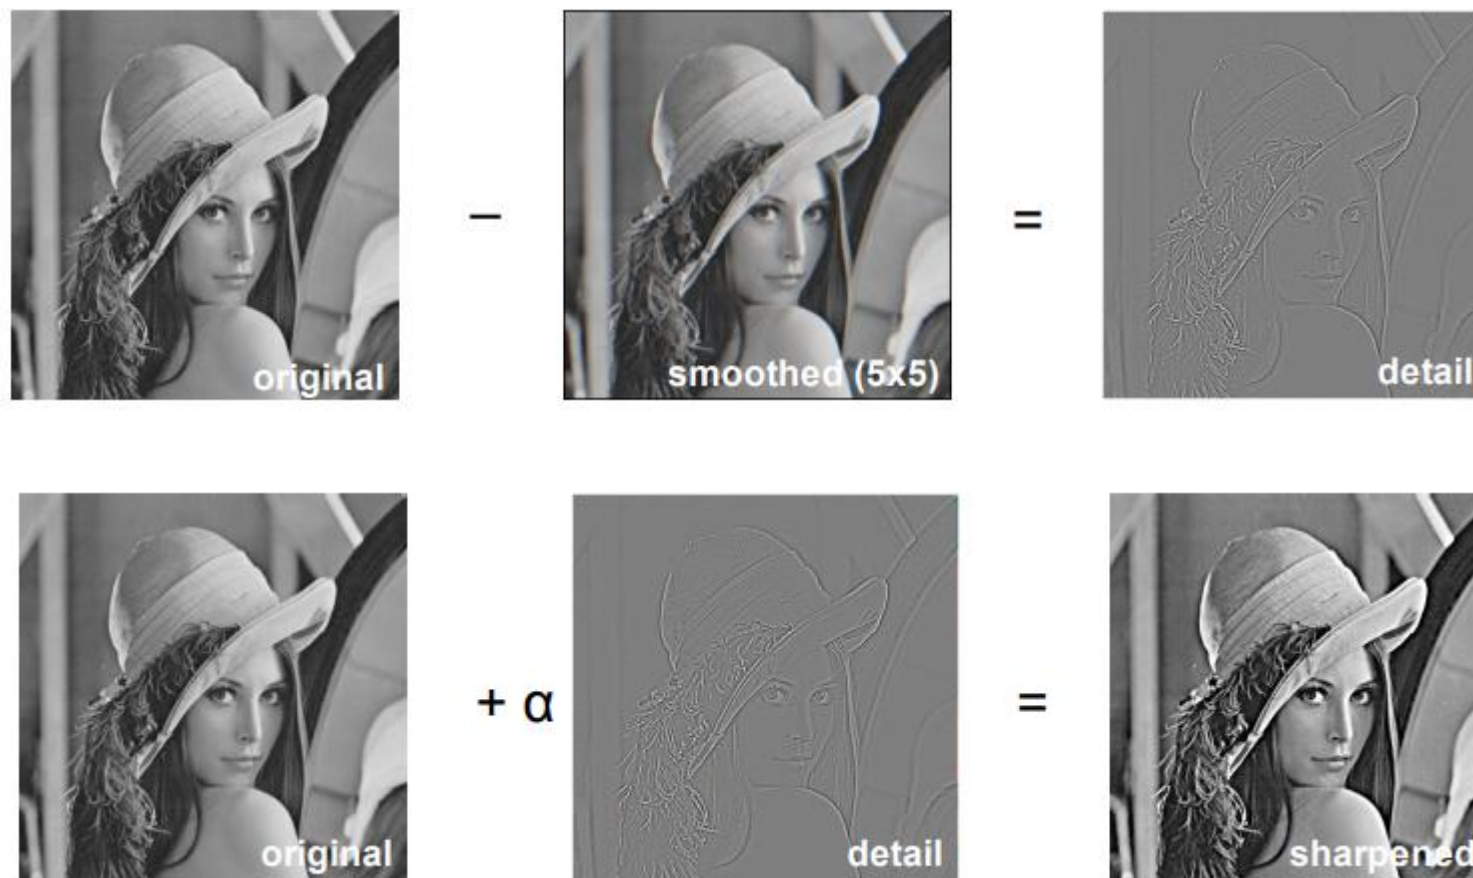


边缘点

求梯度

图像锐化

- 找到图像的边缘，然后把边缘加到原本的图像上，这样就强化了图像的边缘。



图像锐化


- 找到图像的边缘，然后把边缘加到原本的图像上，这样就强化了图像的边缘。




$$\begin{matrix} * & \begin{matrix} -1 & -1 & -1 \\ -1 & 9 & -1 \\ -1 & -1 & -1 \end{matrix} & = \end{matrix}$$



图像锐化



before



after

边界处理

选项一：不做任何处理。（图像滤波（卷积）后会变小）

$F[x, y]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0


$G[x, y]$

	0	10	20	30	30	30	20	10	
	0	20	40	60	60	60	40	20	
	0	30	60	90	90	90	60	30	
	0	30	50	80	80	90	60	30	
	0	30	50	80	80	90	60	30	
	0	20	30	50	50	60	40	20	
	10	20	30	30	30	30	20	10	
	10	10	10	0	0	0	0	0	

边界处理

选项一: 不做任何处理。(图像滤波(卷积)后会变小)

选项二: 对原图像四周填充额外的行或列, 使用不同的策略填充。(可保持图像大小不变)



Zero

填充0值像素

Clamp

填充对应边缘像素

Mirror

与边缘区域对称填充

Wrap

填充对边区域像素

案例分析-1



Original

0	0	0
0	1	0
0	0	0


?

案例分析-1



Original

0	0	0
0	1	0
0	0	0



滤波后
(没有变化)

案例分析-2



Original

0	0	0
0	0	1
0	0	0

?

(假定卷积核已经旋转)

案例分析-2



Original

0	0	0
0	0	1
0	0	0



左移一个像素

(假定卷积核已经旋转)

案例分析-3



Original

 $\frac{1}{9}$

1	1	1
1	1	1
1	1	1

?


案例分析-3



Original

 $\frac{1}{9}$

1	1	1
1	1	1
1	1	1



模糊

案例分析-4



Original

0	0	0
0	2	0
0	0	0

-

$\frac{1}{9}$

1	1	1
1	1	1
1	1	1

?

案例分析-4



Original

0	0	0
0	2	0
0	0	0

-

$\frac{1}{9}$


1	1	1
1	1	1
1	1	1




锐化滤波，注重与平均值的差异

模板匹配

- 模板是我们已知的小图像，模板匹配就是在一副大图像中搜寻目标。
- 解决方案：滤波器的值就是模板的像素值！




图像




模板

模板匹配

- 在要检测的图像上，用滤波器从左到右、从上到下遍历图像，计算滤波器（模板）与重叠子图像的像素匹配度。如果匹配程度高，说明相似度高。




检测到的模板




模板

模板匹配

- 互相关图中亮度最高的地方就是匹配度最大的位置。



检测到的模板



互相关图

模板匹配




图像



模板

如果模板不属于原图像的子图，结果会怎么样？

模板匹配




图像




模板

如果比例、方向和整体外观相近，那么极大可能会匹配成功。

如何将图像缩小？



交替去除一些行和列




1/4




1/8


对图像缩小后再放大，图像失真




原始数据





对原始数据缩小1/2



Step 1: 去除行后



Step2: 去除列后



$1/2$

信息严重丢失!

滤波后下采样



Gaussian 1/2



G 1/4




G 1/8

先对图像进行高斯滤波，然后进行下（子）采样。

- 每减少1/2尺寸，滤波核大小应增加一倍。为什么？

滤波核尺寸增加一倍，每个缩小后的图像对应的像素就考虑了多一倍的像素信息。

过滤后下采样



Gaussian $1/2$




G $1/4$



G $1/8$

无过滤下采样



$1/2$




$1/4$ (2x zoom)



$1/8$ (4x zoom)


如何将图像放大？



最近邻

算法基本思想：令新增像素的灰度值等于距它最近的输入像素灰度值


- 计算简单，但不够精确，有锯齿现象



最近邻

算法基本思想：令新增像素的灰度值等于距它最近的输入像素灰度值

- 计算简单，但不够精确，有锯齿现象



双线性(Bilinear)插值

算法基本思想:


1. 沿X方向线性插值, 在 Q_{12} 和 Q_{22} 之间插入蓝色点 R_2 , 在 Q_{11} 和 Q_{21} 之间插入蓝色点 R_1

$$f(x, y_1) \approx \frac{x_2 - x}{x_2 - x_1} f(Q_{11}) + \frac{x - x_1}{x_2 - x_1} f(Q_{21}),$$

$$f(x, y_2) \approx \frac{x_2 - x}{x_2 - x_1} f(Q_{12}) + \frac{x - x_1}{x_2 - x_1} f(Q_{22}).$$

2. 沿Y方向线性插值, 通过第一步计算出的 R_1 和 R_2 在Y方向插值计算出 P

$$f(P) \approx \frac{y_2 - y}{y_2 - y_1} f(R_1) + \frac{y - y_1}{y_2 - y_1} f(R_2).$$



$$f(x, y_1) \approx \frac{x_2 - x}{x_2 - x_1} f(Q_{11}) + \frac{x - x_1}{x_2 - x_1} f(Q_{21}),$$

推导过程:


$$\text{令 } f(R_1) = f(x, y_1)$$

$$\frac{f(Q_{21}) - f(Q_{11})}{x_2 - x_1} = \frac{f(R_1) - f(Q_{11})}{x - x_1}$$

$$f(R_1) - f(Q_{11}) = (x - x_1) \frac{f(Q_{21}) - f(Q_{11})}{x_2 - x_1}$$

$$f(R_1) = f(Q_{11}) + (x - x_1) \frac{f(Q_{21}) - f(Q_{11})}{x_2 - x_1}$$

$$= \frac{x_2 - x}{x_2 - x_1} f(Q_{11}) + \frac{x - x_1}{x_2 - x_1} f(Q_{21})$$



双三次(Bicubic)插值

算法基本思想:


$f(x, y)$ 的值可以通过矩形网格中最近的十六个采样点的加权平均得到, 需要使用两个多项式插值三次函数, 每个方向使用一个。



最近邻插值



双线性内插



双三次内插

图像超分辨率重建

超分辨率重建开山之作SRCNN:

<http://mmlab.ie.cuhk.edu.hk/projects/SRCNN.html>



Bicubic / 33.91 dB

VS.



SRCNN / 35.01 dB



Bicubic / 32.39 dB

VS.




SRCNN / **34.35** dB




Bicubic / 24.04 dB

VS.



SRCNN / **27.58** dB



Bicubic / 32.58 dB

VS.



SRCNN / **34.91** dB

谢谢！